Arquitectura multiagente

Diseño, implementación y medición de costo y métricas

Ciclo del agente

Pensar → **Actuar** → **Observar**

y vuelve a pensar, hasta cumplir el objetivo o agotar el presupuesto.

Un modelo de lenguaje dentro de un ciclo: decide qué hacer, usa herramientas y ajusta su siguiente paso según lo que observa.

Modelo	Instrucciones	Herramientas	Memoria	Parada
El LLM razona y decide.	Rol, objetivo y formato de salida.	Funciones que puede invocar: buscar, calcular, consultar.	Historial y estado que conserva entre pasos.	Cuándo termina: objetivo, iteraciones o costo.

Universidad ICESI

Ventajas

01
Especialización
Cada agente tiene un rol, un prompt corto y solo las herramientas que necesita.

02
Paralelismo
Las subtareas independientes corren al mismo tiempo y baja la latencia total.

03
Contexto limpio
Cada agente ve solo lo relevante: menos ruido y menos tokens por llamada.

04
Revisión cruzada
Un agente evalúa el trabajo de otro antes de entregar el resultado.

Universidad ICESI

Desventajas

Más llamadas y tokens
Cada traspaso entre agentes repite contexto.

Más latencia
Los pasos secuenciales suman tiempos de espera.

Errores en cascada
La falla de un agente contamina a los siguientes.

Depuración difícil
Sin trazas por agente no se sabe dónde se perdió la calidad.

Regla práctica: empezar con un agente y escalar solo cuando la medición lo justifique.

Universidad ICESI

Seis patrones de diseño



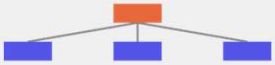
Secuencial

Cada agente transforma la salida del anterior.



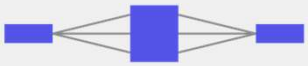
Router

Un clasificador envía cada caso al especialista adecuado.



Orquestador–trabajadores

Un agente planifica, reparte subtareas y une resultados.



Paralelización

Tareas independientes a la vez; se agregan al final.



Evaluador–optimizador

Uno produce, otro critica; se itera hasta aprobar.



Jerárquico

Orquestadores por niveles para problemas grandes.

5 · En naranja, el agente que coordina

Universidad ICESI

Decisiones de diseño

Decisión	Opciones	En el notebook
Control del flujo	Código fijo o el LLM decide	Orquestador LLM con pasos acotados
Comunicación	Texto libre o mensajes estructurados	Esquemas Pydantic en JSON
Memoria	Compartida o privada por agente	Estado compartido con resúmenes
Modelo por rol	Uno para todos o según dificultad	Barato para trabajar, mejor para juzgar
Criterio de parada	Iteraciones, presupuesto o calidad	Máximo 3 rondas del crítico y tope en USD

6

Métricas

Calidad
¿Resolvió la tarea?

Juez LLM con rúbrica; exactitud frente a respuestas de referencia.

Costo
¿Cuánto cuesta cada tarea?

USD por tarea y por agente; tokens de entrada, salida y caché.

Latencia
¿Cuánto tarda?

Percentiles p50 y p95; tiempo de la ruta crítica.

Robustez
¿Qué tan seguido falla?

Tasa de éxito, errores de herramientas y reintentos.

Coordinación
¿Cuánto cuesta coordinar?

Traspasos, porcentaje de tokens de overhead y trabajo duplicado.

7

Cálculo del costo

Una llamada
tokens de entrada × precio de entrada + tokens de salida × precio de salida

Precios en USD por millón de tokens.

Una tarea
La suma de todas las llamadas de todos los agentes, incluidos reintentos y rondas del crítico.

Agente	Llamadas	Entrada	Salida	USD
Orquestador	2	6 000	1 200	0,0012
Investigadores (×3)	9	45 000	9 000	0,0090
Redactor	1	8 000	2 000	0,0018
Crítico	2	10 000	800	0,0014
Total por tarea	14	69 000	13 000	0,0134

Ejemplo ilustrativo con precios hipotéticos de USD 0,10 por millón de tokens de entrada y 0,50 de salida. En el notebook, OpenRouter devuelve el uso real de cada llamada.

8

Ejemplo de Modelos

Modelo	Entrada	Salida	Uso sugerido
DeepSeek V4.1 Flash	0,028	0,12	Recomendado para los trabajadores
GPT-6 Luna	0,10	0,50	Alternativa para trabajadores
Claude Haiku 5.5	0,10	0,50	Juez de calidad de otra familia reduce el sesgo de autoevaluación.
Gemini 3.7 Flash	0,75	3,75	Orquestador o techo de calidad

Precios de referencia en USD por millón de tokens (octubre de 2026). Varían según el proveedor al que OpenRouter enrute la llamada; conviene verificarlos en openrouter.ai/models antes de la clase.

“In God we trust”


José Armando Ordóñez
UNIVERSIDAD ICESI A OTRO NIVEL